Mohamed Aziz Madhbouh

Étudiant en Big Data et Analyse de données

+216 50 557 582 mohamedazizmadhbouh@gmail.com GitHub LinkedIn

Tunisie

Profil professionnel

Étudiant en 3ème année de Licence Big Data et Analyse de données à l'ISAMM, à la recherche d'un stage de fin d'études (PFE) en ingénierie de données, analyse de données ou IA/ML. Conception de pipelines distribués (Hadoop, Spark, Docker) et d'un classificateur de logs CI en Python (F1 macro de 0,77 sur 10 classes) intégrant un LLM et des tableaux de bord Grafana. À l'aise avec Python, SQL, Docker et l'évaluation rigoureuse de modèles.

Formation

Institut Supérieur des Arts Multimédia de la Manouba *2027*

Licence en Big Data & Analyse de données, 3ème année *Tunisie*

Matières principales : systèmes distribués, architecture Big Data, machine learning, entreposage de données, analyse statistique

Projets

Classificateur de logs CI - Lien | *Python, Docker, Jenkins, Grafana, pytest*

- Développement d'un système de classification des logs de builds Jenkins en 10 catégories d'erreur (permission, Docker, base de données, réseau/API, mémoire, timeout, etc.), avec un pipeline complet : prétraitement des textes, entraînement, évaluation et analyse des performances.
- Évaluation du modèle de catégories sur 14 320 logs de test : exactitude de 0,77 et score F1 macro de 0,77 (meilleure classe : erreurs de configuration CI/Git, F1 de 0,88) ; analyse de la généralisation sur des données hors distribution (OOD) pour identifier ses limites face à des logs inédits.
- Intégration d'un LLM (API Gemini) pour prédire le niveau de sévérité des builds (Faible, Moyen, Élevé, Critique), avec rotation automatique entre plusieurs modèles lorsque la limite de requêtes est atteinte.
- Intégration dans un système de surveillance CI conteneurisé : Docker, Jenkins, tableaux de bord Grafana, service de surveillance des builds, migrations de base de données et tests automatisés (plus de 75 commits).

Pipeline d'analyse des véhicules électriques - Lien | *Hadoop, Spark 3.5, Docker Compose, PySpark*

- Construction d'un pipeline Big Data distribué sur un cluster Docker Compose : 1 NameNode HDFS, 3 DataNodes, YARN et un maître Spark avec 3 workers.
- Développement de jobs PySpark lisant depuis HDFS un jeu de données de 67 Mo sur les immatriculations de véhicules et calculant les répartitions par État, ville, constructeur, année du modèle, type de véhicule et autonomie électrique moyenne.

Analyse des achats avec MapReduce - Lien | *Python, Hadoop Streaming, MapReduce*

- Implémentation de scripts mapper et reducer calculant le total des ventes et le nombre de transactions pour 18 catégories de produits sur environ 4,1 millions d'enregistrements d'achats.
- Tests en local avec des pipes Unix, puis exécution sur un cluster Hadoop via Hadoop Streaming.

Prédiction des absences aux rendez-vous médicaux - Lien | *Python, Pandas, scikit-learn, Matplotlib, Seaborn*

- Nettoyage et exploration des données de rendez-vous, création de variables temporelles et visualisation de la répartition des absences.
- Entraînement et comparaison de modèles de régression logistique et de forêt aléatoire (exactitude, précision, rappel, score F1, matrice de confusion).

Compétences

Langages : Python, SQL, Java, R, C/C++ (notions)
Big Data : Apache Hadoop, Apache Spark
Analyse & ML : Pandas, NumPy, scikit-learn, Matplotlib, Seaborn, Jupyter Notebook, ingénierie de variables, prétraitement de texte, classification, évaluation de modèles, intégration d'API LLM
Outils & DevOps : Docker, Docker Compose, Git, GitHub, Jenkins, Grafana, pytest, Maven, JDBC